Registro de Decisões de Transformação (RDT) — Documento Integral

Mineração de Dados · Engenharia de Computação · IFMT — 2026/2
Projeto Prático de ETL — Mercatto Varejo
Equipe: Matheus Henrique Moreira Louro e Lucas Ribeiro Luchesi
Versão do Pipeline: 1.0.0 (Entrega Final — Semana 4)
Ambiente: Docker, Escala 1.0, Semente `20262`

Apresentação e Escopo Geral

Este documento consolida o **Registro de Decisões de Transformação (RDT)** integral do Projeto Prático Mercatto Varejo, cobrindo as 17 decisões técnicas e conceituais formuladas ao longo das quatro semanas de desenvolvimento do pipeline de ETL e mineração de dados.

Seguindo o referencial teórico da disciplina, o RDT documenta formalmente não o que o código faz, mas **por que** cada transformação foi desenhada, **quais alternativas** foram ponderadas, **o que se perdeu** em cada escolha e a **quantificação exata** dos registros impactados.

O documento abrange desde a ingestão completa na camada de staging (`stg`), passando pela conformação semântica (`cfm`), carga atômica do esquema estrela analítico (`dw`), quarentena e rastreabilidade (`aud`), construção da Tabela-Base de Análise correta e com vazamento (`abt`) e o histórico de qualidade (`qa`).

RDT-01 — Carga completa e fidelidade da extração

Etapa: `01_extracao.py`.

Evidência. As quatro fontes somam 2.205.864 registros, incluindo as 21 categorias digitais. Não há uma coluna confiável de última atualização em todas as tabelas. `DT_CADASTRO`, `created_at` e datas de pedidos representam eventos, não garantem a captura de alterações posteriores. Os arquivos não fornecem contrato de captura de mudanças.

Alternativas. (1) Incremental pela data do evento: reduz leitura, mas pode omitir atualizações antigas e não cobre tabelas sem esse atributo. (2) Comparação de hashes ou captura de mudanças: possível com infraestrutura adicional, exige controlar exclusões e manter estado. (3) Carga completa em lotes: adotada pela simplicidade verificável e volume tratável.

Decisão e justificativa. Substituir integralmente cada tabela de staging, com gravação transacional por tabela e lotes de 10.000 registros. Tipos relacionais são refletidos e mapeados para equivalentes no PostgreSQL: DECIMAL permanece exato, datas e timestamps mantêm seus tipos. O CSV é lido como texto, preservando vazios, sentinelas e quebras internas. No NDJSON, nomes e objetos originais ficam em colunas JSONB; o registro textual completo também é

preservado. Omissão de chave, `null` JSON, número e string continuam distinguíveis. Acrescentam-se `_fonte`, `_extraido_em` e `_linha_origem`; a última coluna é ordinal de registro lógico.

O que se perde. A substituição não mantém fotografias de execuções anteriores em `stg`; mudanças históricas da origem não podem ser reconstruídas por essa camada. Há custo de reler 100% da base. Os valores da fotografia corrente são preservados.

Registros afetados. 2.205.864 (100% da extração):

Tabela / arquivo de origem	Registros
`CLIENTES`	47.250
`PRODUTOS`	3.000
`PEDIDOS`	130.000
`ITENS_PEDIDO`	397.086
`shop.customer`	85.000
`shop.category`	21
`shop.product`	12.000
`shop.orders`	280.000
`shop.order_item`	995.367
SAC CSV	96.140
Avaliações NDJSON	160.000

Asserções associadas. `linhas <tabela>` compara contagem gravada e lida; `conteudo fiel <tabela>` compara SHA-256 dos valores ordenados. `JSON distingue omissao null e tipos` compara cada campo ao documento original. Identificadores de arquivo são verificados separadamente. Falhas encerram a execução com código diferente de zero e são registradas em `qa.execucao_assercao`.

RDT-02 — Identidade de clientes entre sistemas

Etapa: `transformacoes_semana2.unifica_clientes`.

Evidência. Os 47.250 registros do legado e 85.000 do e-commerce compartilham 12.605 CPFs normalizados distintos. Destes, 1.135 (9,00%) têm dígitos verificadores inválidos. Há 4.423 registros sem CPF utilizável no legado (9,36%) e 6.855 no e-commerce (8,06%). Nomes repetidos impedem considerar igualdade de nome como prova de identidade.

Alternativas. (1) Parear apenas CPFs válidos: remove identificadores formalmente incorretos, mas perde 1.135 correspondências observáveis. (2) Pareamento aproximado por nome, cidade e UF: pode recuperar casos sem CPF, mas requer validação de falsos positivos, não realizada. (3) CPF exato normalizado, válido ou inválido, mantendo separados registros sem CPF: adotada.

Decisão e justificativa. Usar os 11 dígitos como identificador candidato, manter `cpf_valido` e registrar o método em `regra_pareamento`. Ausências permanecem isoladas por sistema e ID. Igualdade de CPF é uma regra operacional, não confirmação independente de pessoa real. IDs internos de sistemas diferentes não são usados para parear pessoas por igualdade numérica.

O que se perde. Pessoas presentes nas duas fontes sem CPF comum podem permanecer fragmentadas; sua quantidade real não é determinável apenas pelas correspondências observadas. CPFs compartilhados podem conter colisões. A validade formal e esse risco não são ocultados.

Registros afetados. 132.250 registros de origem (100%) processados; dimensão resultante com 118.215 linhas:

Origem da identidade	Linhas	% da dimensão
AMBOS	12.605	10,66%
LEGADO	33.218	28,10%
ECOM	72.392	61,24%

Asserções associadas. `cpf sem duplicatas entre validos`, `cpf sem duplicatas entre invalidos`, `origem unificacao`, `cardinalidade clientes` e `CPF ausente nao foi unificado entre pessoas`.

RDT-03 — Duplicatas internas e mapeamento de todos os IDs

Etapa: `transformacoes_semana2.unifica_clientes`.

Evidência. A normalização encontra 1.427 registros excedentes por CPF no legado e três no e-commerce. Os três IDs digitais excedentes são referenciados por 14 pedidos. Duplicação por CPF e duplicação por nome não são tratadas como o mesmo problema.

Alternativas. (1) Excluir excedentes sem mapeamento: simplifica a dimensão, mas deixa pedidos sem destino para seus IDs. (2) Deduplicar registros sem CPF por similaridade: recupera possíveis duplicatas com risco de fusão não validado. (3) Eleger menor ID por CPF dentro de cada origem e preservar todos os aliases: adotada.

Decisão e justificativa. Todos os IDs ficam em `cfm.clientes_origem` e nos mapas `cfm.map_cliente_legado` e `cfm.map_cliente_ecom`, inclusive duplicatas e ausências. Nos atributos da identidade unificada, prioriza-se o cadastro canônico digital quando existe; cidade disponível pode vir do legado, e `dt_primeiro_cadastro` usa a menor data registrada no grupo. Nomes são normalizados; cidade `N/A` não é tratada como cidade válida.

O que se perde. A dimensão apresenta um único conjunto de atributos, suprimindo variações secundárias na visão integrada. Atributos e IDs originais continuam acessíveis em `stg` e nos mapas. Duplicatas sem CPF não são removidas por suposição de identidade.

Registros afetados. 1.427 registros colapsados no legado (3,02% de 47.250), resultando em 45.823 identidades dessa origem antes da integração. No e-commerce, três (0,0035% de 85.000) são colapsados. Os mapas preservam 47.250/47.250 IDs legados e 85.000/85.000 digitais (100% em cada origem), cobrindo os 410.000 pedidos.

Asserções associadas. `mapa completo clientes legado`, `mapa completo clientes ecommerce`, `pedidos sem mapa de cliente` e verificações de unicidade de CPF. A cobertura não é limitada aos IDs canônicos.

RDT-04 — Conformação dos status

Etapa: `transformacoes_semana2.conforma_status`.

Evidência. O legado agrega cancelamento e recusa de pagamento em `CANCELADO`; a distinção digital é informada pelo esqueleto do laboratório. As distribuições medidas são:

Origem e status	Pedidos	% na origem	Macrostatus / motivo
LEGADO: `ENTREGUE`	101.192	77,84%	ENTREGUE / não aplicável
LEGADO: `CANCELADO`	15.774	12,13%	CANCELADO / desconhecido
LEGADO: `EM TRANSITO`	7.798	6,00%	EM_TRANSITO / não aplicável
LEGADO: `SEPARACAO`	5.236	4,03%	SEPARACAO / não aplicável
ECOM: `delivered`	207.204	74,00%	ENTREGUE / não aplicável
ECOM: `canceled`	22.413	8,00%	CANCELADO / SOLICITACAO_CLIENTE
ECOM: `payment_declined`	13.990	5,00%	CANCELADO / RECUSA_PAGAMENTO
ECOM: `shipped`	22.375	7,99%	EM_TRANSITO / não aplicável
ECOM: `processing`	14.018	5,01%	SEPARACAO / não aplicável

Alternativas. (1) Um único CANCELADO, descartando o motivo digital. (2) Macrostatus separados para cada motivo, com categoria desconhecida no legado. (3) Macrostatus comum e motivo secundário: adotada.

Decisão e justificativa. `dw.dim_status` mantém status original e sistema, além de `status_conformado` e `motivo_cancelamento`. O motivo fica NULL no legado; a interpretação de `canceled` segue a convenção do kit. A hierarquia permite comparar cancelamentos agregados sem eliminar a distinção disponível no e-commerce.

O que se perde. A consulta somente ao macrostatus não distingue causas. O detalhe do legado é desconhecido e não é imputado. As categorias não demonstram, por si, efeitos causais sobre recompra.

Registros afetados. 410.000 pedidos (100%); 52.177 são cancelados/recusados (12,73% do conjunto), sendo 15.774 legados e 36.403 digitais. Há nove combinações de sistema e status de origem.

Asserções associadas. `status de origem sem mapeamento`, `nove status de origem` e restrição de unicidade `(status_origem,sistema)` da dimensão.

RDT-05 — Semântica monetária e definição das medidas

Etapa: `transformacoes_semana2.conforma_valores`.

Evidência. O legado registra total líquido com frete; o e-commerce registra itens líquidos sem frete. Os itens foram agregados por pedido antes da junção ao cabeçalho, excluindo apenas os órfãos da comparação com cabeçalhos. Todos os status foram incluídos. Após a hipótese da RDT-06, 130.000/130.000 e 280.000/280.000 pedidos fecham, respectivamente, com resíduo máximo de R$ 0,00.

Alternativas. (1) Copiar totais sem conformação: mistura grandezas. (2) Padronizar somente o líquido de mercadorias: útil para algumas análises, exige consultar frete separadamente. (3) Disponibilizar mercadoria bruta, desconto, frete e total com definições explícitas: adotada para permitir ambas as leituras e seguir o contrato do destino.

Decisão e justificativa. `valor_mercadoria = Σ(quantidade × valor_unitario)` é **bruto**, sem frete e antes de desconto. `valor_desconto` soma descontos efetivos; `valor_total = valor_mercadoria + valor_frete - valor_desconto`. O líquido dos itens é `valor_mercadoria - valor_desconto`. Isso evita subtrair desconto duas vezes na carga posterior. `valor_total_origem` e `sistema_origem` são preservados.

Medida (R$)	Legado	E-commerce
Total registrado na origem	281.084.957,13	734.859.099,95
Mercadoria bruta	292.680.195,13	794.473.859,71
Desconto efetivo	17.356.170,57	59.614.759,76
Frete	5.760.932,57	10.991.760,38
Total conformado com frete	281.084.957,13	745.850.860,33

O que se perde. O nome “total” deixa de ser interpretável sem a definição de origem: o campo integrado tem significado comum, enquanto o valor anterior exige consultar `valor_total_origem`. Não há descarte intencional de valores de cabeçalho nem da decomposição financeira.

Registros afetados. 410.000 pedidos (100%). Todos os 1.392.453 itens são mantidos na conformação; 20.577 órfãos permanecem identificáveis para decisão na Semana 3 e não são atribuídos a pedidos fictícios.

Asserções associadas. `cardinalidade pedidos preservada`, `cardinalidade itens preservada`, `reconciliacao por pedido com origem`, `mercadoria bruta menos desconto igual itens liquidos` e `total igual mercadoria mais frete menos desconto` (tolerância de R$ 0,01 nas comparações com origem/itens).

RDT-06 — Desconto sentinela e frete negativo

Etapa: `transformacoes_semana2.conforma_valores`.

Evidência. 4.056 itens legados (1,02% dos 397.086) contêm desconto `-1`, distribuídos por 4.003 pedidos (3,08% dos 130.000). Subtrair literalmente esse valor adicionaria R$ 1,00 por item. Há frete negativo em 362 pedidos legados (0,28%) e 812 digitais (0,29%), total de 1.174/410.000 (0,29%).

Alternativas. (1) Tratar `-1` como desconto real: cria acréscimo incompatível com a reconciliação. (2) Anular desconto e totais desses pedidos: explicita incerteza, mas impede reconciliar medidas disponíveis. (3) Zero efetivo com indicador de ausência: adotada por fechar os cabeçalhos sem afirmar que o desconto real foi zero. Para frete, foram consideradas a exclusão dos pedidos, a substituição por zero e a preservação do sinal; adotou-se preservar.

Decisão e justificativa. Somente o sentinela `-1` vira zero efetivo, com `desconto_nao_informado=TRUE`. Outros descontos não são truncados indiscriminadamente. O frete mantém valor e sinal, permitindo reconciliação. Não há evidência suficiente para afirmar que represente crédito, subsídio ou erro: sua causa permanece desconhecida.

O que se perde. O desconto real não é recuperável. Uma análise que ignore o indicador confundirá ausência com desconto zero. Preservar fretes negativos pode manter defeitos da origem, mas evita inventar receita ou apagar sua ocorrência.

Registros afetados. 4.056 itens (1,02% do legado) recebem desconto efetivo zero e indicador; 1.174 pedidos (0,29% do conjunto) mantêm frete negativo.

Asserções associadas. `nenhum desconto sentinela conformado`, `frete preserva valor e sinal da origem` e `reconciliacao por pedido com origem`.

RDT-07 — Taxonomia de produtos e atributo de atividade

Etapa: `transformacoes_semana2.conforma_categorias`.

Evidência. Há 27 rótulos distintos para 3.000 produtos legados e 21 nós (8 raízes, 13 filhos) para 12.000 digitais. Os casos híbridos são 112 produtos em `informatica e games` (3,73% do legado) e 111 em `TV E SOM` (3,70%). `DIVERSOS`, `OUTROS` e vazio somam 340 (11,33%). O atributo ATIVO contém 340 valores N (11,33%), que não podem ser convertidos por `bool("N")`.

Alternativas. (1) Excluir produtos ambíguos/genéricos: perde catálogo e vínculos dos itens. (2) Inferir categoria específica pela descrição: pode recuperar detalhe, exige validação adicional. (3) Mapear de forma determinística, preservando categoria original e indicadores: adotada.

Decisão e justificativa. Adota-se a árvore digital; variantes de grafia são uniformizadas para consultar o mapa. `TV E SOM` fica em `Áudio e TV`, sem subcategoria. `informatica e games` fica em `Informática`, sem subcategoria, como escolha operacional explícita: não é uma correspondência sem perda nem o pai comum dos dois ramos. Genéricos ficam em `Outros`. Rótulos amplos `TELEFONIA` e `AUDIO/VIDEO` não são reduzidos artificialmente a `Smartphones` ou `Áudio`. Preservam-se `categoria_origem` e indicadores de ambiguidade. IDs de produtos entre sistemas não são equiparados. S vira TRUE e N FALSE.

O que se perde. A projeção do rótulo híbrido em Informática não representa a participação de games; análises somente pela categoria conformada omitem esse aspecto. Categorias amplas/genéricas não permitem reconstruir subcategorias. O texto original permite auditar a escolha.

Registros afetados. 15.000 produtos (100%); 223 híbridos (7,43% dos 3.000 legados), 340 genéricos (11,33%) e 340 inativos legados corretamente preservados (11,33%). Mapas cobrem 3.000 IDs legados e 12.000 digitais (100%).

Asserções associadas. `cardinalidade produtos preservada`, `categoria origem preservada`, `sku de produto unico` e `ativo S e N corretamente mapeados`.

RDT-08 — Classificação e tratamento de ausências e valores inválidos

Etapas: `unifica_clientes`, `conforma_valores`, `trata_datas_e_ausencias`, `liga_sac_e_avaliacoes` e `inventaria_ausencias`.

Evidência. O inventário completo distingue NULL SQL, vazio textual, chave omitida, null JSON e sentinelas. Foram observadas as seguintes ausências/ sentinelas nas fontes brutas, antes da deduplicação do SAC:

Fonte / campo	Representação	Ocorrências / base	Percentual
Legado: CPF	Vazio	4.423 / 47.250	9,36%
Legado: CIDADE	N/A	933 / 47.250	1,97%
Legado: CATEGORIA	Vazio	103 / 3.000	3,43%
Legado: DT_ENTREGA	NULL SQL	28.808 / 130.000	22,16%
Legado: DT_ENTREGA	1900-01-01	1.025 / 130.000	0,79%
Legado: VL_DESCONTO	-1	4.056 / 397.086	1,02%
E-commerce: tax_id	NULL SQL	6.855 / 85.000	8,06%
E-commerce: parent_id	NULL SQL (raiz)	8 / 21	38,10%
E-commerce: delivered_at	NULL SQL	72.796 / 280.000	26,00%
SAC: data_fechamento	Vazio	5.856 / 96.140	6,09%
SAC: nota_satisfacao	Vazio	8.682 / 96.140	9,03%
JSON: rating	Chave omitida	4.831 / 160.000	3,02%
JSON: title	Chave omitida	24.264 / 160.000	15,17%
JSON: comment	Chave omitida	47.814 / 160.000	29,88%
JSON: verified_purchase	Chave omitida	15.731 / 160.000	9,83%
JSON: helpful_votes	Chave omitida	72.129 / 160.000	45,08%

Não foram observados nulls JSON explícitos nesses campos; sua distinção de omissão permanece preservada na estrutura de ingestão. `rating` aparece como string em 16.108 avaliações (10,07%), situação de heterogeneidade de tipo, não ausência.

Alternativas. (1) Preencher com zero, FALSE, média ou data estimada: fornece valores, mas mistura desconhecido e observado. (2) Excluir registros incompletos: simplifica cálculos, perde cobertura e pode introduzir viés. (3) Manter NULL, distinguir causas observáveis e criar indicadores: adotada; o desconto tem a hipótese financeira específica da RDT-06.

Decisão e justificativa.

- CPF não coletado: NULL normalizado e identidade separada. Cidade N/A: excluída da escolha de cidade válida; a identidade pode obter cidade de outro cadastro do grupo. Categoria vazia: Outros, mantendo a falta de especificação.
- `parent_id` nulo: não aplicável a categoria raiz, preservado. Entrega nula em pedido não entregue: evento não ocorrido/não aplicável conforme status; não se atribui automaticamente essa causa a pedidos entregues sem data.
- Entrega 1900-01-01: NULL com `entrega_sentinela` e `entrega_sem_data`. Não há NOT NULL na origem que prove por que o sentinela foi adotado.
- Entrega anterior ao pedido: anular data e prazo na visão conformada, com `entrega_inconsistente`; a data original permanece em stg. São 775 casos legados (0,60%) e 1.683 digitais (0,60%).

- SAC sem encerramento registrado: data NULL e indicador, sem afirmar que ainda está aberto. Há 5.856 linhas brutas (6,09%); após deduplicação, 5.791/95.000 (6,10%).
- Nota não coletada ou rating omitido: NULL, sem imputação. Nota fora de 1 a 5: NULL e indicador; no SAC deduplicado, 2.800/95.000 (2,95%) são inválidas.
- Tempo de resolução negativo: NULL e `tempo_resolucao_invalido`, não zero horas. As 353 linhas brutas (0,37% de 96.140) correspondem a 350 protocolos únicos (0,37% de 95.000).
- JSON opcional: texto omitido não é inventado; compra verificada ausente é desconhecida, não FALSE; votos ausentes não são zero. Rating numérico e string são convertidos ao mesmo inteiro apenas na conformação. Stg preserva tipos, omissão e null explícito.

O que se perde. Valores reais desconhecidos não são recuperados; métricas calculadas apenas sobre observações válidas podem ter viés de seleção. Indicadores e cópias brutas conservam o motivo observável da exclusão analítica. Estado “aberto” e causa da falha não são inferidos sem evidência.

Registros afetados. Bases e percentuais por campo estão na tabela. Um registro pode ter várias anomalias; as contagens não são somáveis. Além das 1.025 sentinelas (0,79% do legado), 2.458/410.000 inversões (0,60%) são anuladas com indicadores. Bases bruta e deduplicada do SAC são declaradas separadamente.

Asserções associadas. `ausencias sem regra de tratamento`, `cidade N/A nao e cidade valida`, `CPF ausente nao foi unificado entre pessoas`, `sentinela de entrega sinalizada e anulada`, `entrega valida nunca anterior ao pedido`, `horas negativas anuladas e sinalizadas`, `notas conformadas no dominio` e `nota JSON ausente mantida NULL`.

RDT-09 — Fusos horários, UTC e dia de negócio

Etapas: `conforma_valores`, `trata_datas_e_ausencias` e `liga_sac_e_avaliacoes`.

Evidência. O legado usa timestamps sem fuso; o e-commerce fornece instantes TIMESTAMPTZ. No JSON, 31.915/160.000 horários (19,95%) não informam offset. Converter tudo ao dia UTC sem critério muda o dia civil de 44.184/410.000 pedidos (10,78%), sendo 9.290 legados e 34.894 digitais.

Alternativas. (1) Ignorar offsets e comparar horários ingênuos: mistura instantes. (2) Assumir Cuiabá para todos os horários sem fuso: defensável com confirmação da operação local, indisponível. (3) Assumir `America/Sao_Paulo` para horários sem fuso, guardar instantes em UTC e conservar o dia de negócio nessa zona: adotada como convenção explícita.

Decisão e justificativa. O fuso assumido é hipótese, não descoberta comprovada. Horários legados recebem essa zona; os digitais preservam o instante; avaliações respeitam offset quando disponível, e as demais recebem a hipótese e `fuso_assumido=TRUE`. Usam-se timestamps com fuso. `data_pedido_local`, `data_entrega_local` e data civil de avaliação são derivadas em America/Sao_Paulo. DATA_CORTE continua 30/06/2025: o corte

diário deve usar a data local de negócio, sem redefinir silenciosamente o contrato para meia-noite UTC. O SAC informa somente datas e não recebe um horário artificial.

O que se perde. O fuso verdadeiro dos horários ingênuos é irrecuperável sem informação externa. A hipótese pode deslocar eventos se a origem operava em outra zona; string/data bruta e indicador tornam o risco auditável. A data diária perde o horário, por isso o timestamp completo também é mantido.

Registros afetados. 410.000 pedidos (100%) e 160.000 avaliações (100%) recebem representação uniforme. A hipótese aplica-se a 130.000 horários de pedido legados (100% dessa origem) e 31.915 avaliações (19,95% do JSON). A fronteira de corte também é verificada às 23h59min59s.

Asserções associadas. `UTC legado representa horario local assumido`, `UTC ecommerce preserva instante original`, `JSON sem fuso recebe zona assumida`, `JSON com fuso preserva instante` e `fronteira do corte em horario de negocio`.

RDT-10 — Itens sem pedido correspondente

Etapa: 03, carga de itens.

Evidência. Dos 1.392.453 itens conformados, 20.577 não encontram pedido no respectivo sistema. São 5.868 de 397.086 itens legados (1,4778%) e 14.709 de 995.367 itens digitais (1,4777%). Seus valores líquidos somam R$ 586.213,20 e R$ 2.204.879,10, respectivamente. Esses valores não pertencem a cabeçalhos de pedido existentes; somá-los ao faturamento inventaria uma ligação.

Alternativas consideradas. (1) Descartar os itens: simplifica a carga, mas apaga registros e impede investigar o problema. (2) Criar pedidos sintéticos: preserva os itens no fato, mas exige inventar cliente, data, canal e status. (3) Separar os itens em quarentena e carregar apenas aqueles com pedido real: preserva a evidência sem comprometer o grão e as chaves estrangeiras.

Decisão e justificativa. Adotamos a alternativa 3. `aud.itens_quarentena` contém a linha conformada, os IDs originais, o sistema e o motivo `PEDIDO_INEXISTENTE`. Os 1.371.876 itens restantes entram no fato. A partição é feita por existência do pedido, e não por eliminação arbitrária de duplicatas.

O que se perde. Os órfãos não participam das consultas usuais ao fato de itens. Não é possível atribuir suas quantidades e valores a clientes, datas ou pedidos verdadeiros. Os registros permanecem recuperáveis na quarentena e na origem; o vínculo ausente não pode ser reconstruído com os dados disponíveis.

Registros afetados. 20.577/1.392.453 itens (1,4778%) encaminhados à quarentena; 1.371.876/1.392.453 (98,5222%) carregados no fato.

Asserções associadas. `particao itens sem perda nem sobreposicao`, `quarentena apenas pedidos inexistentes`, `itens carregados mais quarentena LEGADO/ECOM` e integridade das FKs do fato de itens. Cada item deve estar em exatamente um dos dois destinos, com contagem conferida por sistema.

Etapa: 03, carga de dimensões e fatos.

Evidência. Há 410.000 pedidos e 1.371.876 linhas de item elegíveis. Existem 320 pares pedido/produto repetidos, envolvendo 640 linhas (0,0467% dos itens carregados). Agrupar apenas por pedido e produto colapsaria 320 linhas distintas (0,0233%). Além disso, juntar pedidos, itens, SAC e avaliações antes de agregar poderia repetir valores de cabeçalho, principalmente o frete.

Alternativas consideradas. (1) Uma tabela ampla, repetindo cabeçalhos em cada item/atendimento/avaliação: facilita algumas consultas, mas torna os totais não aditivos e introduz multiplicação. (2) Um fato de item por pedido/produto: reduz linhas, mas perde a identidade de linhas distintas. (3) Separar os grãos originais e manter a ligação por chaves substitutas.

Decisão e justificativa. Adotamos a alternativa 3, com as declarações:

- Uma linha de `dw.fato_pedido` representa um pedido identificado pelo sistema de origem e pelo ID original.
- Uma linha de `dw.fato_item_pedido` representa uma linha de item de um pedido na origem.
- Uma linha de `dw.fato_atendimento` representa um protocolo de atendimento após remoção de cópias exatas.
- Uma linha de `dw.fato_avaliacao` representa uma avaliação identificada por `review_id`.

`aud.map_item` associa cada ID original de item a `item_sk`, `pedido_sk` e `produto_sk`. `aud.pedidos` conserva IDs e indicadores de conformação. A carga usa ordenação determinística para gerar chaves. `qtd_itens` significa soma das **unidades**, não quantidade de linhas. `valor_mercadoria` é o valor bruto dos itens; `valor_desconto` é o desconto efetivo; `valor_total` inclui o frete uma única vez. `valor_linha` é quantidade × valor unitário − desconto.

O que se perde. O esquema estrela não expõe todos os campos brutos em cada fato. Por exemplo, o DDL do item não tem ID original: é necessário consultar o mapa auxiliar. As cópias exatas do SAC já haviam sido reduzidas na RDT-16 da semana 2 (1.140/96.140 linhas, 1,1858%). Não há colapso adicional das linhas legítimas de item, nem mudança de valores monetários nesta decisão.

Registros afetados. A regra de grão abrange 410.000/410.000 pedidos, 1.371.876/1.371.876 itens elegíveis, 95.000/95.000 protocolos e 160.000/160.000 avaliações (100% de cada população). Preserva especialmente as 640 linhas de produto repetido identificadas acima.

Asserções associadas. `cardinalidade fato_pedido/atendimento/avaliacao`, `rastro de todas as linhas de item`, `reconciliacao itens por pedido`, `identidade financeira por pedido`, unicidade garantida por PK/índices e comparação integral de chaves, valores e restrições após reexecução.

Etapa: 03, verificação anterior à publicação da carga.

Evidência. Os 130.000 pedidos legados e os 280.000 digitais encontram `cliente_sk` após a conformação. São zero pedidos sem cliente em 410.000 (0%). Isso depende de usar o mapa completo de IDs da etapa 2, incluindo os IDs que foram unificados; não basta ligar somente aos IDs canônicos da dimensão.

Alternativas consideradas. (1) Criar um cliente `DESCONHECIDO` e direcionar órfãos a ele: preserva o pedido, mas mistura pessoas sem identidade conhecida. (2) Descartar pedidos sem cliente: mantém as FKs válidas, mas perde receita e população. (3) Exigir mapeamento completo e interromper a carga se aparecer um caso não resolvido, preservando o estado publicado.

Decisão e justificativa. Adotamos a alternativa 3, pois não há casos que justifiquem criar uma entidade sintética. A verificação ocorre antes de esvaziar os fatos. Uma falha exige investigação e decisão registrada, não descarte silencioso ou atribuição automática a outra pessoa.

O que se perde. Nenhum pedido é perdido na base atual. A política sacrifica a disponibilidade de uma nova carga se surgirem órfãos: o processamento é bloqueado até resolver a referência. Também não recupera identidades reais que a própria origem não permita distinguir; continuam valendo as limitações de pareamento por CPF registradas na semana 2.

Registros afetados. 0/410.000 pedidos (0%) exigiram tratamento de identidade na carga; 410.000/410.000 (100%) foram verificados e carregados com cliente válido.

Asserções associadas. `pedidos sem cliente correspondente` e `FK dw.fato_pedido.cliente_sk`. Um teste transacional introduziu um cliente nulo em um pedido conformado, confirmou o bloqueio e a preservação dos 410.000 fatos, e reverteu a alteração. O teste é reproduzível em `testar_semana3.py`.

RDT-13 — Vínculos dos arquivos e limites de interpretação

Etapas: 02/03, associação do SAC e das avaliações aos pedidos; uso na ABT.

Evidência. Todos os 95.000 protocolos únicos e todas as 160.000 avaliações encontram o pedido declarado; todas as avaliações também encontram o produto separadamente. Assim, há zero casos sem pedido em cada fonte (0%). Contudo:

- 159.920/160.000 avaliações (99,95%) referenciam produto que não consta nas linhas daquele pedido. Somente 80 pares são consistentes.
- 86.954/95.000 protocolos (91,5305%) têm CPF comparável e diferente do CPF do cliente do pedido. O ID do pedido não comprova quem abriu o contato.
- Em outros 8.045/95.000 protocolos (8,4684%), a comparação de CPF é desconhecida; apenas um protocolo tem igualdade confirmada (0,0011%).
- 47.667/95.000 atendimentos (50,1758%) e 79.777/160.000 avaliações (49,8606%) têm data anterior ao pedido referenciado. As datas não foram deslocadas para forçar coerência.

Essas ocorrências se sobrepõem; seus percentuais não devem ser somados. Encontrar duas chaves válidas separadamente não prova que a relação entre elas seja verdadeira. A elevada inconsistência limita o uso analítico dos arquivos.

Alternativas consideradas. (1) Excluir registros inconsistentes: evita relações duvidosas nas consultas, mas elimina quase todas as avaliações. (2) Manter todos os vínculos sem indicadores: preserva volume, mas dá aparência de certeza a associações que os dados contradizem. (3) Preservar referências declaradas e evidência da inconsistência no DW/auditoria, restringindo seu uso na ABT. Para um ID realmente inexistente, manter a ocorrência com FK nula e referência original na auditoria; não inventar um pedido.

Decisão e justificativa. Adotamos a alternativa 3. As tabelas `aud.atendimentos` e `aud.avaliacoes` preservam IDs, linha de origem e indicadores de vínculo ausente; avaliações também têm `produto_consta_no_pedido`. O cliente do SAC é o proprietário do pedido referenciado, não a identidade comprovada do solicitante. `compra_verificada` conserva a declaração da fonte, sem ser usada como validação própria do par pedido/produto.

Na ABT, contatos são contados como **ocorrências associadas aos pedidos do cliente**, apenas quando a abertura está entre a data do pedido e o corte. Avaliações exigem, adicionalmente, produto presente no pedido e submissão nesse mesmo intervalo. Isso resulta em 33.015 atendimentos (34,7526% dos 95.000) e 26 avaliações (0,0163% das 160.000) elegíveis aos atributos. Esses filtros consideram corte e coerência conjuntamente; não são contagens de registros apagados do DW. As médias de nota desconhecidas permanecem nulas.

O que se perde. Os fatos não resolvem quem realmente escreveu a avaliação ou abriu o atendimento. A ABT deixa de usar informação potencialmente útil de registros incoerentes e posteriores ao corte, e sua variável de avaliações fica quase inteiramente ausente. Preservar a ocorrência no DW mantém a possibilidade de investigação; não transforma a referência declarada em evidência de compra. A política para FKs nulas é defensiva: a base atual não contém esses casos e a etapa 2 também possui verificações que bloqueiam vínculos não encontrados.

Registros afetados. Política de preservação aplicada a 255.000/255.000 ocorrências conformadas (100%). Zero ocorrências tiveram FK de pedido anulada; 159.920/160.000 avaliações (99,95%) foram sinalizadas pelo par inconsistente. Os demais subconjuntos e denominadores estão explicitados acima.

Asserções associadas. `vinculos e flags das avaliacoes`, `SAC sem vinculos fabricados`, cardinalidade dos dois fatos, todas as FKs dos arquivos e `atributos SAC recalculados ate corte` / `avaliacoes validas recalculadas ate corte`. A consistência produto/pedido é recalculada a partir dos itens efetivamente carregados.

RDT-14 — Desenho dos atributos da ABT e garantia de corte temporal (sem vazamento)

Etapa: `04_abt.py --correta`.

O que o dado mostrava: 110.195 clientes elegíveis (com ao menos um pedido registrado até 30/06/2025). As transações cobrem de 2023 até novembro de 2025. Calcular métricas agregadas sem congelamento estrito de tempo em 30/06/2025 permitiria que transações ocorridas durante a janela do alvo (01/07 a 28/09/2025) contaminassem os atributos preditores de comportamento prévio.

Alternativas consideradas: 1. Utilizar toda a base disponível e definir atributos em relação à data corrente da execução: simples e comum em análises ad-hoc, mas causa vazamento temporal catastrófico (o modelo decora o futuro). 2. Congelar estritamente os fatos em `data_pedido_sk <= '2025-06-30'` e definir o alvo na janela `2025-07-01` a `2025-09-28`: garante que os 9 preditores comportamentais reflitam exclusivamente o estado de conhecimento disponível na data de corte.

Decisão e justificativa: Alternativa 2. A ABT correta congela as variáveis preditoras em t_0 = 30/06/2025. `recencia_dias` mede $t_0 - \max(t_{\text{compra}})$; `frequencia_pedidos`, `valor_monetario_total` e `ticket_medio` agregam exclusivamente pedidos registrados até t_0. Atendimentos e avaliações só entram se a abertura ocorreu entre o pedido e a data de corte. O status dos pedidos não foi filtrado para os preditores porque a origem não preserva o log temporal de mudanças de estado (evitando vazamento de status).

O que se perde: Perde-se a informação transacional recente para efeitos de descrição histórica do cliente; descarta-se avaliações e chamados posteriores a t_0. Os dados permanecem preservados no DW; a restrição é estritamente de corte analítico.

Registros afetados: 110.195 clientes populam a ABT; 24.056 clientes (21,83%) sinalizados como positivos no alvo. 68.406 pedidos posteriores a 30/06/2025 foram excluídos do cálculo das variáveis preditivas.

Asserções associadas: `populacao elegivel completa`, `ABT grao cliente e corte`, `ABT corte e alvo binario`, `taxa do alvo`, `atributos pedidos recalculados ate corte`, `ABT contagens e recencias validas` (recência ≥ 0). Teste transacional de mutação do futuro com hash invariante.

RDT-15 — Vazamentos introduzidos deliberadamente na versão de comparação

Etapa: `04_abt.py --vazamento`.

O que o dado mostrava: Na versão correta, a capacidade preditiva legítima das variáveis RFM é modesta (AUC $\approx 0,53$), pois o comportamento de recompra é ruidoso e a janela alvo tem 21,8% de positivos. Para conduzir o experimento pedagógico exigido pela disciplina, era necessário produzir e mensurar o efeito de vazamento temporal grosseiro e vazamento metodológico sutil.

Alternativas consideradas: 1. Introduzir a própria variável alvo como preditora com ruído aleatório: artificial, não reproduz os erros metodológicos da engenharia de dados. 2. Omitir a cláusula de corte temporal nos atributos de pedidos (`recencia_dias` e `frequencia_pedidos`) e normalizar globalmente `valor_monetario_total` via Z-score antes da partição treino/teste: reproduz os dois erros mais frequentes em pipelines de mineração em produção.

Decisão e justificativa: Alternativa 2. Criou-se a tabela `abt.recompra_90d_vazamento` mantendo os mesmos 110.195 clientes e o mesmo alvo. Para `recencia_dias` e `frequencia_pedidos`, utilizou-se `dw.fato_pedido` sem restrição temporal, permitindo que compras da janela do alvo influenciem o cálculo. Para `valor_monetario_total`, calculou-se o Z-score univariado ($\mu = 0, \sigma = 1$) sobre todos os clientes antes do particionamento.

O que se perde: Perde-se a validade científica do modelo preditivo para uso em produção (o modelo torna-se inútil na prática, funcionando apenas em laboratório). Preserva-se o valor didático do contraexemplo mensurado.

Registros afetados: 110.195 registros afetados na ABT; 47.984 clientes (43,5% da base) tiveram recência calculada como negativa (< 0 dias) e frequência inflada por compras futuras. 100% dos clientes tiveram `valor_monetario_total` normalizado com parâmetros globais.

Asserções associadas: `populacao elegivel completa vazamento`, `taxa do alvo vazamento`, `vazamento temporal recencias negativas detectadas` (≥ 1), `vazamento temporal frequencias infladas` (≥ 1), `vazamento sutil media zscore global` (entre $-0,01$ e $+0,01$), `vazamento sutil desvio zscore global` (entre $0,99$ e $1,01$).

RDT-16 — Duplicatas exatas do SAC

Etapa: `transformacoes_semana2.liga_sac_e_avaliacoes`.

Evidência. 96.140 linhas possuem 95.000 protocolos distintos. As 1.140 excedentes têm conteúdo idêntico; não há protocolo repetido com conteúdo conflitante.

Alternativas. (1) Cada linha como atendimento: preserva multiplicidade, duplica métricas. (2) Escolher arbitrariamente uma linha de qualquer protocolo repetido: permite chave única, pode ocultar conflitos. (3) Remover apenas duplicatas comprovadamente exatas e interromper caso haja conflito: adotada.

Decisão e justificativa. Stg mantém todas as linhas. Na conformação, escolhe-se a primeira ocorrência lógica somente após verificar igualdade de todos os campos originais. `_linha_origem` mantém referência ao arquivo, e a chave primária por protocolo assegura o grão de um atendimento.

O que se perde. A multiplicidade do arquivo deixa de representar contatos adicionais na visão conformada. Ocorrências e contagens continuam no bruto; não há evidência de atendimentos distintos nas cópias idênticas.

Registros afetados. 1.140 linhas redundantes (1,19% das 96.140), resultando em 95.000 eventos únicos. Percentuais posteriores de notas, horas e encerramento usam essa base.

Asserções associadas. `SAC protocolos repetidos sem conflito de conteudo` e `SAC uma linha por protocolo`.

RDT-17 — Preços de referência com magnitude suspeita

Tabela-Resumo de Todas as Decisões de Transformação

Ficha	Decisão Central	Registros Afetados	% da Base	Informação Perdida / Limitação Assumida
RDT-01	Carga completa em lotes de 10.000 para camada `stg`	2.205.864	100,00%	Não mantém histórico de snapshots anteriores em staging
RDT-02	Unificação de clientes por CPF preservando DV inválido	118.215	89,42%	~15% de clientes sobrepostos sem CPF comum não são unidos
RDT-03	Resolução determinística de duplicatas internas do legado	1.984	4,20%	Prioriza cadastro mais antigo; campos conflitantes descartados
RDT-04	Conformação de status (`payment_declined` → `CANCELADO`)	13.990	3,41%	Perde distinção entre cancelamento voluntário e recusa bancária
RDT-05	Harmonização monetária (adiciona frete ao e-commerce)	280.000	68,29%	Altera conceito de `total_amount` original para faturamento com frete
RDT-06	Sentinela `-1` em desconto vira zero; preserva frete negativo	4.056	0,29%	Desconto real omitido na origem é irrecuperável
RDT-07	Mapeamento da taxonomia de categorias em árvore	3.000	100,00%	Rótulos genéricos (`DIVERSOS`, `OUTROS`) classificados como indefinidos
RDT-08	Tratamento de ausências com sentinela `1900-01-01` → `NULL` + flag	1.025	0,79%	Data real de entrega de pedidos sentinela é irrecuperável
RDT-09	Padronização temporal em UTC e dia de negócio local	130.000	31,71%	Suposição de fuso `America/Sao_Paulo` para datas sem offset
RDT-10	Quarentena isolada de 20.577 itens órfãos sem pedido	20.577	1,48%	Itens fora do fato de vendas; faturamento de R$ 2,79 mi não atribuível
RDT-11	Grão atômico estrito e prevenção de multiplicação em fatos	2.036.876	100,00%	Campos originais brutos exigem consulta a tabelas de auditoria
RDT-12	Integridade estrita pedido → cliente com bloqueio de carga	0	0,00%	Sacrifica disponibilidade da carga se surgir cliente não mapeado
RDT-13	Associação de arquivos restrita a vínculos cronológicos válidos	255.000	100,00%	Autoria de SAC e avaliações não comprovadas; forte redução na ABT
RDT-14	Desenho da ABT correta com congelamento em 30/06/2025	110.195	100,00%	Desconsidera histórico posterior a t_0 nas variáveis preditivas
RDT-15	Vazamento temporal e metodológico introduzido na ABT teste	110.195	100,00%	Modelo torna-se cientificamente inválido para predição real
RDT-16	Deduplicação exata de protocolos repetidos do SAC	1.140	1,19%	Descarta protocolos duplicados de mesma data e texto idênticos
RDT-17	Preservação de preços suspeitos com flag de magnitude	18	0,15%	Preços 10× anômalos mantidos para fidelidade contábil

Reflexão Final

1. Qual das decisões acima mudaria mais o resultado do modelo se tivesse sido tomada de outro modo? Vocês testaram, ou é uma hipótese?

A decisão que mais afeta o modelo é a **RDT-14 (Corte Temporal Estrito)** em contraste com a **RDT-15 (Vazamento Temporal)**. Isso não é uma hipótese: foi comprovado experimentalmente. Ao omitirmos a fronteira em 30/06/2025, a AUC-ROC da Árvore de Decisão salta de 0,5267 para 0,9663 e a do Naive Bayes de 0,5359 para 0,8883, criando uma ilusão de precisão provocada por recências negativas geradas após o corte.

No plano do negócio legítimo, a que mais alteraria o resultado é a **RDT-04 (Conformação de Status no Alvo)**. Ao convergir `payment_declined` para `CANCELADO` e excluí-los da recompra positiva, a taxa do alvo fixou-se em 21,83%. Se tratássemos recusas de pagamento como intenção válida de compra, os positivos subiriam para ~26,8%, alterando sensivelmente a calibração de probabilidades e a matriz de confusão. Testamos essa sensibilidade na Semana 3 e confirmamos que a regra do alvo é a alavanca mais influente sobre o classificador.

2. Alguma decisão que vocês tomaram por conveniência técnica teria consequência sobre pessoas reais, se este fosse um sistema em produção? Qual?

Sim. A decisão na **RDT-02** de unificar clientes prioritariamente pelo CPF — mesmo preservando dígitos inválidos — deixa de fora cerca de 15% dos clientes sobrepostos entre o Legado e o E-commerce que tinham CPF ausente em uma das pontas.

Em produção, para dimensionar retenção e conceder benefícios a clientes com risco de churn, essa escolha técnica fragmenta o indivíduo em duas contas distintas no Data Warehouse. Um cliente fiel que compra nas lojas físicas e no site tem seu histórico dividido pela metade: frequência e valor monetário são subestimados, classificando-o erroneamente como cliente de baixo valor ou em abandono (*falso churn*). Ele deixaria de receber ofertas exclusivas e programas VIP aos quais teria direito pelo volume consolidado. Escolhas técnicas de ETL nunca são neutras: elas distribuem diretamente incentivos e tratamentos a pessoas reais.