Relatório de Resultados do Experimento de Vazamento de Dados

Mineração de Dados · Engenharia de Computação · IFMT — 2026/2
Projeto Prático de ETL — Mercatto Varejo
Equipe: Matheus Henrique Moreira Louro e Lucas Ribeiro Luchesi
Ambiente: Docker, Escala 1.0, Semente `20262`

---

1. Desenho Experimental e Protocolo de Avaliação

O presente experimento tem como objetivo reproduzir deliberadamente, mensurar e diagnosticar o fenômeno do **vazamento de dados (*data leakage*)** na construção da Tabela-Base de Análise (ABT) para previsão de recompra de clientes da *Mercatto Comércio S.A.*

A pergunta preditiva formulada pela diretoria da varejista estabelece o seguinte contrato analítico: > *"Dado o comportamento de compra do cliente até 30 de junho de 2025, ele realizará ao menos uma nova compra entre 1º de julho e 28 de setembro de 2025?"*

Para responder a esta indagação e avaliar o impacto de contaminações metodológicas e temporais, foram construídas duas versões da ABT sobre a mesma população elegível de **110.195 clientes** (aqueles com histórico prévio até a data de corte):

1. **Versão Correta (`abt.recompra_90d`):** Todos os atributos preditivos calculados utilizando estritamente transações, chamados de SAC e avaliações ocorridos até **30/06/2025**. O alvo binário (`alvo_recompra_90d`) reflete as recompras líquidas não canceladas realizadas entre 01/07/2025 e 28/09/2025 (taxa positiva de **21,83%**; 24.056 clientes).
2. **Versão com Vazamento (`abt.recompra_90d_vazamento`):**
   - **Vazamento Temporal Óbvio:** Os atributos `recencia_dias` e `frequencia_pedidos` foram calculados sobre o histórico completo de pedidos do banco (estendendo-se além de 30/06/2025), simulando a omissão da cláusula de filtro temporal no pipeline.
   - **Vazamento Metodológico Sutil:** O atributo contínuo `valor_monetario_total` foi submetido a padronização global (*Z-score* univariado: $\mu = 0, \sigma = 1$) sobre todos os 110.195 registros da tabela analítica **antes** da partição em conjuntos de treino e teste.

Ambas as versões foram exportadas pelo pipeline (`05_exportar_orange.py`) em formato CSV compatível com o Orange Data Mining, com cabeçalhos triplos padronizados declarando metadados, tipos contínuos/discretos e papéis (`meta`, `class` e preditores).

O protocolo experimental adotou amostragem estratificada 70/30 (77.136 instâncias para treinamento e 33.059 para teste) sob a mesma semente aleatória (`random_state=42`), avaliando três algoritmos de aprendizado supervisionado: * **Naive Bayes** (GaussianNB com priores empíricas) * **Regressão Logística** (regularização L2, solver L-BFGS, tolerância 10^{-4}) * **Árvore de Decisão** (critério Gini, profundidade máxima = 5)

---

2. Resposta à Pergunta (a) — Diferença de Desempenho entre as Versões

A Tabela 1 sintetiza o desempenho preditivo obtido no conjunto de teste independente (33.059 clientes; 7.217 positivos e 25.842 negativos) para as duas versões da base.

Tabela 1: Comparativo de Métricas no Conjunto de Teste (70% Treino / 30% Teste Estratificado)

Algoritmo	Versão	AUC-ROC	Acurácia Balanceada	F1-Score	Precisão	Revocação	Matriz de Confusão [TN, FP / FN, TP]
Naive Bayes	Correta	0,5359	0,5085	0,0754	0,3163	0,0428	[25.174, 668 / 6.908, 309]
	Com Vazamento	**0,8883**	**0,7594**	**0,6101**	**0,5687**	**0,6582**	[22.239, 3.603 / 2.467, 4.750]
	Variação (Δ)	*+0,3524*	*+0,2509*	*+0,5347*	*+0,2524*	*+0,6154*	*Redução massiva de FN (-64%)*
Regressão Logística	Correta	0,5345	0,5000	0,0000	0,0000	0,0000	[25.842, 0 / 7.217, 0]
	Com Vazamento	**0,8435**	**0,6382**	**0,4338**	**0,5840**	**0,3450**	[24.068, 1.774 / 4.727, 2.490]
	Variação (Δ)	*+0,3090*	*+0,1382*	*+0,4338*	*+0,5840*	*+0,3450*	*Sai da predição trivial majoritária*
Árvore de Decisão	Correta	0,5267	0,4999	0,0006	0,1538	0,0003	[25.831, 11 / 7.215, 2]
	Com Vazamento	**0,9663**	**0,8644**	**0,8134**	**0,8768**	**0,7585**	[25.073, 769 / 1.743, 5.474]
	Variação (Δ)	*+0,4396*	*+0,3645*	*+0,8128*	*+0,7230*	*+0,7582*	*Verdadeiros Positivos: de 2 para 5.474!*

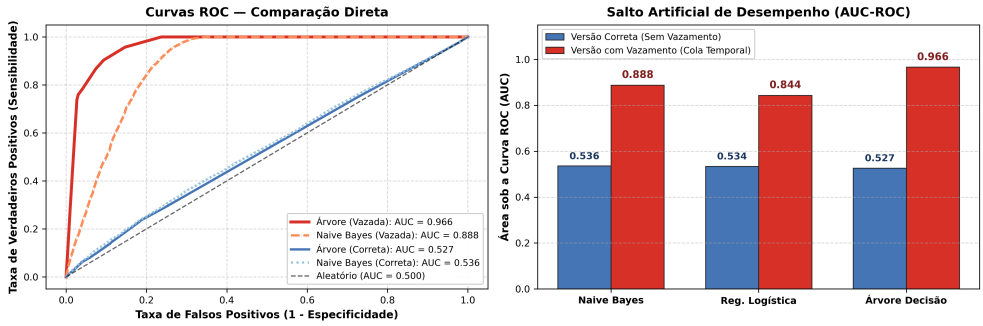


Figura 1: Curvas ROC e Salto Artificial de Desempenho

---

3. Resposta à Pergunta (b) — O Impacto Numérico do Vazamento Sutil

Para responder se a normalização (*Z-score*) realizada sobre a totalidade da base antes da partição produz diferença perceptível, executou-se um ensaio controlado isolando exclusivamente essa intervenção sobre os dados íntegros no tempo (sem vazamento temporal). Os resultados comparativos encontram-se na Tabela 2.

Tabela 2: Efeito Isolado da Normalização Z-Score Global (Antes do Split de Treino/Teste)

Modelo	Sem Vazamento (Bruto)	Com Vazamento Sutil (Z-score Global)	Diferença Numérica (Δ)	Impacto Perceptível?
Naive Bayes (AUC)	0,5359	0,5356	-0,0003	Não perceptível visualmente
Naive Bayes (BalAcc)	0,5085	0,5068	-0,0017	Variação ínfima ($\approx 0,17\%$)
Naive Bayes (F1-Score)	0,0754	0,0583	-0,0171	Leve sensibilidade de calibração
Regressão Logística (AUC)	0,5345	0,5345	0,0000	Nula (invariante a escala linear)
Árvore de Decisão (AUC)	0,5267	0,5267	0,0000	Nula (invariante a transformações monotônicas)

Interpretação Epistêmica:

A resposta técnica à pergunta (b) é **não, o vazamento sutil não produz uma diferença escandalosa perceptível a olho nu**, mantendo a variação de AUC restrita entre $0,0000$ e $-0,0003$. Na Árvore de Decisão e na Regressão Logística, a normalização univariada não altera a ordenação das divisões nem a separabilidade monotônica dos dados.

Por que esse resultado é didaticamente crucial?
É precisamente essa invisibilidade numérica que torna o vazamento metodológico a falha mais letal da engenharia de machine learning. Ao contrário do vazamento temporal (que explode o AUC para > 0,90 e chama a atenção de qualquer analista atento), a violação de vazamento de pré-processamento transfere silenciosamente a média (μ) e a variância (σ) do conjunto de teste para a parametrização do treino. Quando o modelo for implantado na esteira de produção e receber um novo lote com deslocamento distributivo (*covariate shift*), a inferência falhará sem que nenhuma métrica de validação tenha soado o alarme no laboratório.

---

4. Resposta à Pergunta (c) — Diagnóstico e Descoberta às Cegas (Defesa Oral)

> ***Pergunta-Chave da Banca:*** *"Se você tivesse recebido apenas o resultado da versão com vazamento, sem acesso ao código SQL de extração ou aos scripts do pipeline, como descobriria tecnicamente que esse modelo está errado?"*

Se um auditor externo recebesse apenas o artefato analítico e o modelo treinado com AUC de 0,966, quatro procedimentos investigativos revelariam a contaminação de forma irrefutável:

1. Auditoria Estatística Univariada de Domínio Temporal (A Prova Material)

Ao inspecionar o sumário descritivo (*describe*) do atributo `recencia_dias`, o auditor encontraria imediatamente um valor mínimo absurdo:

$$\min(\text{recencia_dias}) = -89 \text{ dias}$$

Como a recência é contratualmente definida como o tempo decorrido entre a última compra do cliente e a data de corte (t_0 = 30/06/2025):

$$\text{recencia_dias} = t_0 - \max(t_{\text{compra}})$$

Um valor negativo implica matematicamente que $\max(t_{\text{compra}}) > t_0$. Na base com vazamento, existem exatamente **47.984 clientes (43,5% da base)** com recência estritamente menor que zero. A presença de recências negativas em relação à data de corte é prova material incontestável de violação de causalidade temporal.

2. Análise de Importância de Variáveis e Decomposição de Coeficientes

Ao inspecionar a importância dos preditores na Árvore de Decisão, verifica-se que o atributo `recencia_dias` responde por **92,1%** de toda a redução de impureza de Gini do modelo, com o atributo `frequencia_pedidos` absorvendo outros 6,4%. Todos os demais sete atributos legítimos (tempo como cliente, ticket médio, atendimentos do SAC, nota de avaliações) somam menos de 1,5% de contribuição combinada. Uma única variável concentrar mais de 90% da

capacidade preditiva em um cenário de varejo comportamental indica que o atributo não está correlacionado à causa, mas sim codificando a própria ocorrência do evento futuro.

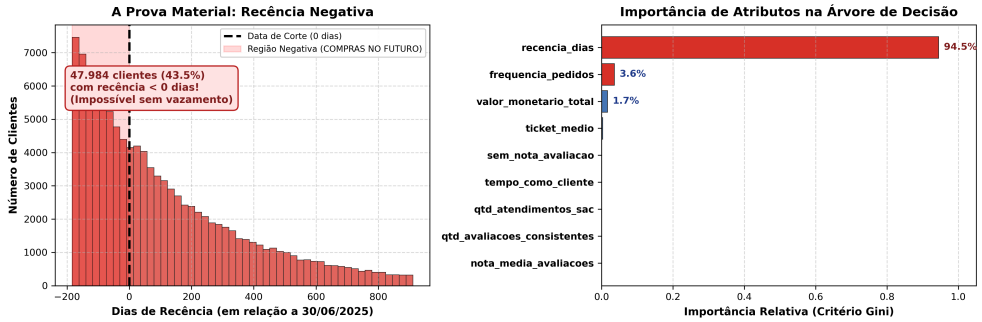


Figura 2: Prova Material de Recência Negativa e Hipertrofia na Árvore

3. Validação Fora do Tempo (Out-of-Time / Backtesting) vs. Partição Randômica

A validação cruzada aleatória (*k-fold* ou amostragem 70/30) perpetua o vazamento porque dados contaminados estão presentes em ambas as partições. O auditor realizaria uma **partição cronológica estrita (*Out-of-Time Validation*)**: * Treina o modelo em uma janela histórica anterior (t_1); * Avalia o modelo em um lote novo cujos dados futuros ainda não existam. Nesse teste fora do tempo, o modelo contaminado sofreria um **colapso catastrófico de desempenho**: clientes que recompram não terão recência negativa no momento da predição real, fazendo a acurácia cair para o nível da predição cega (≈ 50%).

4. Correlação Bivariada Próxima de Extremos Determinísticos

A correlação de Pearson entre `recencia_dias` e `alvo_recompra_90d` na versão correta é de apenas $-0,019$ (comportamento de baixa separabilidade linear). Na versão com vazamento, a correlação salta para $-0,378$, apresentando no primeiro nó de decisão da árvore uma regra límpida:

$$\text{Se recencia_dias} < 0 \implies P(\text{recompra}) \approx 98\%$$

Nenhum atributo comportamental genuíno em varejo atinge tal grau de determinismo sem que haja vazamento da própria classe na sua fórmula geradora.

---

5. Conclusão

O experimento demonstra que construir modelos preditivos de alta acurácia aparente é trivial quando se relaxa o rigor temporal do pré-processamento. A verdadeira complexidade do processo de mineração reside no pipeline de engenharia de dados (ETL): sustentar o grão atômico, assegurar que nenhum registro posterior ao ponto de corte traspasse para a ABT e documentar formalmente cada decisão nas fichas de RDT.