Relatório de Diagnóstico — Mercatto Varejo

Mineração de Dados · IFMT · Entrega 1
Equipe: Matheus Henrique Moreira Louro e Lucas Ribeiro Luchesi
Ambiente: Docker, escala 1,0, semente 20262

1. Objetivo e método

Diagnosticar as fontes MySQL legado, PostgreSQL do e-commerce, CSV do SAC e NDJSON de avaliações antes da integração. As medições abrangem as bases completas, sem alteração das origens, e complementam o perfilador fornecido. O objetivo do projeto é prever a recompra entre 01/07/2025 e 28/09/2025 usando o comportamento até 30/06/2025.

2. Questão (a) — Chaves de junção e cobertura

Cobertura = 100 × registros com correspondência / registros examinados. Cada registro é contado uma vez, mesmo quando sua chave encontra várias ocorrências. Ausências e duplicatas integram o denominador; valores vazios não são pareados. CPF e telefone foram comparados somente por dígitos; e-mail, em minúsculas e sem espaços externos; nomes, sem acentos, em maiúsculas e com espaços uniformizados.

2.1. Clientes entre os sistemas

Candidato	Valores distintos compartilhados	Legado: cobertos / 47.250	E-commerce: cobertos / 85.000
`CPF` ↔ `tax_id`	12.605	13.048 (27,61%)	12.606 (14,83%)
`NOME` ↔ `full_name`	22.869	28.204 (59,69%)	31.360 (36,89%)
`EMAIL` ↔ `email`	0	0 (0,00%)	0 (0,00%)
`TELEFONE` ↔ `phone`	0	0 (0,00%)	0 (0,00%)

O **CPF é o principal candidato**, mas não garante identidade nem unicidade: 1.427 valores se repetem no legado e 3 no e-commerce; somente 12.161 dos 12.605 CPFs compartilhados são únicos em ambos. Entre os compartilhados, 1.135 (9,00%) têm dígito verificador inválido; excluí-los eliminaria correspondências observáveis. O nome apresenta maior cobertura, porém há 6.758 nomes repetidos no legado e 15.477 no e-commerce, exigindo critérios adicionais para evitar unir pessoas distintas. E-mail e telefone não ligam os cadastros nesta base. Os IDs internos dos dois sistemas também não comprovam identidade entre fontes.

2.2. Arquivos para pedidos, clientes e produtos

Candidato e destino	Cobertos / examinados	Cobertura
SAC: `(origem_sistema, id_pedido_origem)` → pedido na origem indicada	96.140 / 96.140	100,00%
SAC: `cpf_cliente` → qualquer cadastro	90.155 / 96.140	93,77%
SAC: `cpf_cliente` → cadastro da origem indicada	88.535 / 96.140	92,09%
JSON: `order.ref` → pedido da origem indicada	160.000 / 160.000	100,00%
JSON: `product.sku` → produto da origem indicada	160.000 / 160.000	100,00%

A chave de pedido deve incluir a origem, pois IDs podem coincidir entre os bancos. No SAC, `LEGADO` e `ECOM` direcionam a busca a `ID_PEDIDO` e `order_id`. No JSON, `LEG-<id>` referencia IDs do legado, `ECOM-<id>` referencia pedidos do e-commerce e `SKU-<n>` corresponde a `shop.product.sku`. São 40.016 avaliações do legado e 119.984 do e-commerce, com cobertura de 100% para pedidos e produtos em cada grupo.

A ligação do SAC por pedido cobre todas as linhas, inclusive as 5.985 (6,23%) sem CPF em nenhum cadastro. Nas avaliações, a existência de pedido e produto foi verificada separadamente; não comprova que o produto pertence ao pedido. `protocolo` e `review_id` identificam registros locais, sem contraparte direta nos bancos.

2.3. Relações internas dos bancos

Relação e campo da chave	Legado: cobertos / examinados	E-commerce: cobertos / examinados
Pedido → cliente: `ID_CLIENTE` / `customer_id`	130.000 / 130.000 (100%)	280.000 / 280.000 (100%)
Item → pedido: `ID_PEDIDO` / `order_id`	391.218 / 397.086 (98,52%)	980.658 / 995.367 (98,52%)
Item → produto: `ID_PRODUTO` / `product_id`	397.086 / 397.086 (100%)	995.367 / 995.367 (100%)

Há 5.868 itens sem pedido no legado e 14.709 no e-commerce (1,48% em cada origem). IDs de produto de sistemas diferentes não estabelecem equivalência comercial.

3. Questão (b) — Heterogeneidade semântica

Foram identificados três casos em que campos aparentemente equivalentes representam conceitos diferentes. Variações de idioma, grafia ou formato, isoladamente, não constituem divergência semântica.

3.1. Cancelamento e recusa de pagamento

Segundo o esqueleto de conformação fornecido, `CANCELADO` no legado agrega cancelamento pelo cliente e recusa de pagamento; o e-commerce distingue `canceled` de `payment_declined`. As distribuições confirmam a diferença de abrangência:

Sistema e status	Pedidos / total da origem	Percentual
Legado: `CANCELADO`	15.774 / 130.000	12,13%
E-commerce: `canceled`	22.413 / 280.000	8,00%
E-commerce: `payment_declined`	13.990 / 280.000	5,00%

A soma dos dois estados no e-commerce é 36.403 pedidos (13,00%). Comparar apenas `canceled` com `CANCELADO` excluiria as recusas da segunda fonte. Agrupar os estados permite comparação mais ampla, mas perde a distinção disponível no e-commerce. O motivo específico não pode ser recuperado no legado.

3.2. Composição do valor do pedido

`VALOR_TOTAL` do legado inclui frete; `total_amount` do e-commerce corresponde ao valor líquido dos itens. Essa diferença foi confirmada nos 130.000 pedidos do legado e nos 280.000 do e-commerce (100% de cada origem), com resíduo máximo de R$ 0,00 nas respectivas fórmulas. Comparar ou somar esses

campos diretamente misturaria medidas distintas. A prova e os critérios de reconciliação estão na questão (c).

3.3. Abrangência das categorias de produto

O legado tem 27 rótulos distintos, considerando caixa e acentos, para 3.000 produtos; o e-commerce tem 21 nós de categoria (8 raízes e 13 filhos), para 12.000 produtos. "Categoria" pode representar um ramo, uma categoria específica ou uma combinação de ramos:

- `informatica e games`: 112 produtos (3,73% do legado), reunindo dois ramos separados no e-commerce.
- `TV E SOM`: 111 (3,70%), reunindo `Televisores` e `Áudio`, que classificam 793 e 805 produtos no e-commerce.
- `DIVERSOS`, `OUTROS` e vazio: 340 (11,33%), sem ramo comercial identificável.

Padronizar grafias não resolve essas diferenças de significado. Atribuir uma categoria combinada a um único ramo descartaria parte da classificação; separá-la exige informação adicional por produto. Os 27 rótulos, portanto, não equivalem a 27 categorias comerciais.

4. Questão (c) — Reconciliação financeira

Os campos não medem a mesma coisa: `VALOR_TOTAL` inclui frete, enquanto `total_amount` o exclui. Para verificar, os itens foram agregados por ID de pedido antes da junção ao cabeçalho, evitando repetir totais e fretes. Foram examinados todos os pedidos, independentemente do status; itens órfãos não entram na soma de nenhum pedido existente.

Para cada pedido p, definiu-se o valor líquido dos itens:

$$L_p = \sum_{i \in I_p} (q_i u_i - d_i^*)$$

Em que I_p são os itens do pedido, q_i é a quantidade, u_i o preço unitário praticado e d_i^* o desconto da linha. Foram usados `QTD`, `VL_UNITARIO` e `VL_DESCONTO` no legado; `quantity`, `unit_price` e `discount` no e-commerce.

No legado, o sentinela `VL_DESCONTO = -1` contribuiu como zero no teste. Essa hipótese é compatível com os totais registrados, mas não recupera o desconto real ausente. Há 4.056 itens com esse sentinela em 4.003 pedidos (3,08% dos 130.000); subtrair literalmente `-1` acrescentaria R$ 1,00 por item e faria esses pedidos falharem na reconciliação. Os fretes foram usados com o sinal original, inclusive quando negativos.

Hipótese para o total registrado	Legado: 130.000 pedidos	E-commerce: 280.000 pedidos
$L_p + \text{frete}_p$	130.000 (100,00%)	94 (0,03%)
L_p, sem frete	33 (0,03%)	280.000 (100,00%)

A tolerância foi R$ 0,02 por pedido. Nas fórmulas confirmadas, o maior resíduo absoluto foi **R$ 0,00**. As 33 e 94 coincidências com a hipótese alternativa decorrem de fretes cuja magnitude está dentro da tolerância. A reconciliação agregada também confirma o resultado:

Medida agregada (R$)	Legado	E-commerce
Soma dos totais registrados	281.084.957,13	734.859.099,95
Soma dos itens líquidos	275.324.024,56	734.859.099,95
Soma dos fretes	5.760.932,57	10.991.760,38

No legado, **281.084.957,13 = 275.324.024,56 + 5.760.932,57**. No e-commerce, a soma dos totais já é igual à soma dos itens líquidos; incluir frete exigiria acrescentar R$ 10.991.760,38. Portanto, uma medida comparável de total com frete deve manter `VALOR_TOTAL` no legado e adicionar `freight_amount` a `total_amount` no e-commerce, preservando a origem das medidas.

5. Questão (d) — Anomalias e limites do diagnóstico

[A desenvolver.]

6. Questão (e) — Grão das tabelas-fato

[A desenvolver.]

Referências e reprodução

Projeto Prático ETL Mercatto, seção 3.1; Dicionário de Dados e esqueleto de transformação do laboratório. Medições: `diagnostico_chaves.py` e `diagnostico_semantica.py`, na pasta `etl`; resultados em arquivos JSON homônimos, na pasta `saida`.